

Etap 2 – Plan Rozwiązania

Adam Basiewicz, Paola Jaroń, Weronika Kaźmierczak, Mikołaj Lepsy

1. Kluczowe Wskaźniki Efektywności (KPI)

Kluczowe Wskaźniki Efektywności (KPI) stanowią fundament analityczny systemu MusicaBI, łącząc zidentyfikowane potrzeby biznesowe z techniczną strukturą modelu wielowymiarowego. Projektowany dashboard ma za zadanie wspierać menedżerów A&R oraz wytwórnie muzyczne w podejmowaniu krytycznych decyzji inwestycyjnych, takich jak podpisywanie kontraktów z nowymi artystami czy strategiczny wykup praw do twórczości. Zdefiniowane poniżej metryki zostaną umieszczone na samej górze interfejsu użytkownika, stanowiąc pierwszy punkt styku dla decydenta i umożliwiając błyskawiczną ocenę sytuacji rynkowej. Każde z wybranych KPI odpowiada bezpośrednio na kluczowe pytania analityczne, transformując surowe strumienie danych z platform Spotify, Last.fm oraz Google Trends w strategiczną wiedzę o trendach i dynamice popularności w branży muzycznej.

- KPI: Wskaźnik Dynamiki Wzrostu (Growth Velocity - % / punktów)

Pytanie biznesowe: Którzy artyści osiągnęli największy wzrost popularności na Spotify w ostatnich 30 dniach?

- KPI: Wynik Potencjału Przebiccia (Breakout Score - index)

Pytanie biznesowe: Jakie jest zestawienie top 20 artystów według breakout_score w bieżącym miesiącu, z podziałem na gatunek muzyczny i kraj pochodzenia?

- KPI: Wskaźnik Zaangażowania (Engagement Rate - stosunek aktywności do słuchaczy)

Pytanie biznesowe: Którzy undergroundowi artyści wykazują najwyższy wskaźnik zaangażowania (engagement) mimo małej liczby słuchaczy?

- KPI: Trwałość Trendu (Liczba miesięcy)

Pytanie biznesowe: Którzy artyści utrzymują stabilnie wysoką popularność przez ponad 6 miesięcy, a nie tylko chwilowy trend?

2. Szczegóły Modelu Wielowymiarowego

W tej sekcji przedstawiono techniczną strukturę modelu wielowymiarowego dla systemu MusicaBI, który realizuje proces codziennego monitorowania popularności oraz wykrywania trendów rynkowych .

Tabela Faktów: Fact_Artist_Daily_Metrics

Tabela faktów rejestruje codzienne, mierzalne zdarzenia i metryki charakteryzujące pozycję rynkową poszczególnych twórców .

- Fakt: Dzienna rejestracja popularności i dynamiki wzrostu artysty.
- Ziarno: Jeden rekord odpowiada aktywności jednego artysty w konkretnym dniu .
- Miary i reguły agregacji:
 - Miara: spotify_popularity
 - Typ miary: Póładdytywna (wartość punktowa)
 - Metoda agregacji: AVG (uśrednianie w wybranym przedziale czasu)
 - Miara: spotify_followers
 - Typ miary: Póładdytywna (skumulowany przyrost)
 - Metoda agregacji: MAX (reprezentuje stan na ostatni dzień analizowanego okresu)
 - Miara: lastfm_listeners
 - Typ miary: Póładdytywna
 - Metoda agregacji: MAX lub AVG
 - Miara: lastfm_playcount
 - Typ miary: Póładdytywna
 - Metoda agregacji: MAX
 - Miara: google_trends_score
 - Typ miary: Póładdytywna
 - Metoda agregacji: AVG
 - Miara: growth_velocity
 - Typ miary: Nieaddytywna (wartość obliczeniowa / procentowa)
 - Metoda agregacji: AVG
 - Miara: breakout_score

- Typ miary: Nieaddytywna (indeks potencjału)
- Metoda agregacji: AVG lub MAX

Tabele Wymiarów

Tabele wymiarów stanowią kontekst biznesowy dla metryk zgromadzonych w tabeli faktów, odpowiadając na pytania: kto, kiedy, gdzie oraz w jakim otoczeniu wydawniczym osiągnął dany wynik.

- Wymiar: Dim_Artist (Wymiar Artysty)
 - Atrybuty: artist_id , name , country , debut_year , musicbrainz_id , spotify_id , lastfm_id.
 - Krótki opis: Unikalny rejestr monitorowanych artystów wraz z ich profilami, pochodzeniem i identyfikatorami systemowymi .
 - Ziarno: Jeden unikalny artysta.
- Wymiar: Dim_Date (Wymiar Czasu)
 - Atrybuty: date_id , day , week , month , quarter , year.
 - Krótki opis: Kalendarz umożliwiający pełną analizę trendów w ujęciu dziennym, tygodniowym, miesięcznym, kwartalnym i rocznym.
 - Ziarno: Jeden dzień kalendarzowy.
- Wymiar: Dim_Album (Wymiar Albumu)
 - Atrybuty: album_id , title , release_date , album_type , artist_id.
 - Krótki opis: Dane o wydawnictwach powiązanych z artystami, pozwalające ocenić stabilność wzrostu po premierach płytowych.
 - Ziarno: Jeden album.

Opcjonalne tabele słownikowe (struktura Snowflake):

- Wymiar: Dim_Genre (Słownik Gatunków)
 - Atrybuty: genre_id , genre_name.
 - Krótki opis: Słownik przechowujący ujednolicone nazwy gatunków muzycznych.
 - Ziarno: Jeden gatunek muzyczny.
- Wymiar: Dim_Community_Tag (Słownik Tagów)
 - Atrybuty: tag_id , tag_name.
 - Krótki opis: Tagi społecznościowe Last.fm charakteryzujące niszę artysty.
 - Ziarno: Jeden unikalny tag.

Hierarchie (Ścieżki nawigacyjne)

Zdefiniowane ścieżki nawigacyjne określają, w jaki sposób użytkownicy biznesowi (menedżerowie A&R) mogą przechodzić od ogólnych podsumowań rynkowych do szczegółowych danych analitycznych.

- Hierarchia Czasowa: Pozwala na analizę stabilności trendów w różnych oknach czasowych .
 - Dzień -> Miesiąc -> Kwartał -> Rok
 - Poziomy i klucze:
 - Poziom: Dzień | Identyfikator: day
 - Poziom: Miesiąc | Identyfikator: month
 - Poziom: Kwartał | Identyfikator: quarter
 - Poziom: Rok | Identyfikator: year
- Hierarchia Geograficzno-Wykonawcza: Służy do filtrowania i tworzenia rankingów regionalnych.
 - Kraj -> Artysta
 - Poziomy i klucze:
 - Poziom: Kraj | Identyfikator: country
 - Poziom: Artysta | Identyfikator: artist_id
- Hierarchia Struktury Portfolio: Wspiera analizę wpływu premier na profil artysty.
 - Artysta -> Album
 - Poziomy i klucze:
 - Poziom: Artysta | Identyfikator: artist_id
 - Poziom: Album | Identyfikator: album_id

3. Przygotowanie do procesu ETL

Mapa logiczna procesu ETL

W tej sekcji zaplanowano proces pobierania, czyszczenia i transformacji surowych danych ze źródeł API (Spotify, Last.fm, Google Trends, MusicBrainz) przed ich załadowaniem do docelowego modelu płatka śniegu . Ze względu na specyfikę pobieranych danych, kluczowym elementem będzie deduplikacja, obsługa wartości pustych (NULL) oraz ujednolicanie formatów tekstowych .

Cel (Tabela docelowa)	Źródło danych	Transformacje i reguły ładowania
-----------------------	---------------	----------------------------------

Tabela: Dim_Artist Typ tabeli: Wymiar Atrybuty: artist_id, name, country, musicbrainz_id Typ danych: INT, VARCHAR SCD: Type 1 / 2	Źródła: Spotify API, Last.fm API, MusicBrainz API Atrybut źródłowy: artist_name, country, musicbrainz_id	1. Ujednolicenie tekstu: Zmiana wielkości liter, usunięcie znaków specjalnych i emoji z nazw artystów . 2. Deduplikacja: Rozwiązanie problemu duplikatów i aliasów poprzez twarde mapowanie przy użyciu niezawodnego klucza musicbrainz_id. 3. Obsługa braków: Zamiana wartości NULL w kolumnie kraju na domyślną wartość "Unknown".
Tabela: Dim_Album Typ tabeli: Wymiar Atrybuty: album_id, title, release_date Typ danych: INT, VARCHAR, DATE SCD: Type 1	Źródła: Spotify API, MusicBrainz API Atrybut źródłowy: album_title, release_date	1. Czyszczenie tytułów: Usunięcie zbędnych sufiksów z tytułów albumów, takich jak "(Remastered)", "(Deluxe Edition)" czy "(Bonus Track Version)". Zamiana brakujących tytułów na domyślny "Single". 2. Formatowanie dat: Ujednolicenie trzech różnych formatów dat ze Spotify (YYYY, YYYY-MM, YYYY-MM-DD) do pełnego formatu daty. Uzupełnienie braków datą sztuczną, np. 1900-01-01.
Tabela: Dim_Genre Typ tabeli: Wymiar (Słownik) Atrybuty: genre_id, genre_name Typ danych: INT, VARCHAR	Źródła: Spotify API, Last.fm API Atrybut źródłowy: genre	1. Standaryzacja: Czyszczenie "wolnych tagów" i naprawa literówek poprzez mapowanie do ujednoliconej, zamkniętej listy gatunków. 2. Obsługa braków: W przypadku nowych artystów (dla których algorytmy nie zebrały jeszcze danych) mapowanie brakujących gatunków na "Unknown".

SCD: Type 1		
Tabela: Fact_Artist_Daily_Metrics Typ tabeli: Fakt Atrybuty: metric_id, date_id, spotify_popularity, google_trends_score, growth_velocity, is_estimated Typ danych: INT, FLOAT, BOOLEAN	Źródła: Spotify API, Last.fm API, Google Trends Atrybut źródłowy: popularity, followers, listeners, trends_score	1. Integracja: Złączenie danych metrycznych z wielu źródeł po kluczu daty oraz identyfikatorze artysty (łączenie w jeden dzienny rekord). 2. Imputacja danych i flagowanie: W przypadku braku danych z Google Trends (częste dla niszowych twórców), wstawienie wartości 0 do kolumny google_trends_score oraz aktywacja flagi is_estimated = TRUE. 3. Kalkulacja metryk: Dynamiczne wyliczenie miar pochodnych, takich jak growth_velocity oraz breakout_score, na podstawie pobranych wartości surowych.

Przygotowanie Planu Procesu

Architektura hurtowni opiera się na modelu płatka śniegu, gdzie centralne miejsce zajmuje tabela faktów, do której wpływają dane otoczone tabelami wymiarowymi stanowiącymi słowniki i kontekst.

Podsekcja 1: Wymiary

Wymiary to tabele słownikowe, które nadają kontekst analityczny dla badanych zdarzeń w czasie.

1. Tabela: Dim_Artist

- **Źródła:** Spotify API, Last.fm API, MusicBrainz API.
- **Transformacje:** Normalizacja wielkości liter oraz usunięcie skrótów i znaków specjalnych z nazw . Deduplikacja artystów i mapowanie aliasów przy użyciu stałego klucza musicbrainz_id . Zastąpienie pustych wartości w kolumnie kraju tagiem "Unknown".

- **Plan weryfikacji:** * *Unikalność:* Sprawdzenie, czy klucz główny artist_id nie zawiera duplikatów.
 - *Kompletność:* Test wykluczający obecność wartości NULL w kluczowych polach tekstowych po procesie mapowania.

2. Tabela: Dim_Album

- **Źródła:** Spotify API, MusicBrainz API.
- **Transformacje:** Usunięcie sufiksów tekstowych z tytułów (np. "(Remastered)", "(Deluxe Edition)"). Ujednolicenie różnych wariantów dat do jednego formatu (YYYY-MM-DD). Zamiana brakujących tytułów na słowo "Single".
- **Plan weryfikacji:**
 - *Spójność dat:* Weryfikacja, czy wszystkie rekordy w kolumnie release_date posiadają poprawny format daty i czy nie występują tam logiczne błędy.

3. Tabela: Dim_Genre

- **Źródła:** Spotify API, Last.fm API.
- **Transformacje:** Zebranie "wolnych tagów" ze źródeł, naprawa literówek i zmapowanie ich do zamkniętego słownika gatunków muzycznych. Obsługa braku przypisanego gatunku (częste dla nowych artystów na Spotify) poprzez wstawienie wartości "Unknown".
- **Plan weryfikacji:**
 - *Integralność słownika:* Sprawdzenie zapytań grupujących, upewniając się, że nie powstały zduplikowane gatunki różniące się jedynie wielkością liter.

Podsekcja 2: Fakty

Tabela faktów przechowuje mierzalne zdarzenia biznesowe oraz klucze obce umożliwiające łączenie z wymiarami.

1. Tabela: Fact_Artist_Daily_Metrics

- **Źródła:** Spotify API, Last.fm API, Google Trends.
- **Transformacje:** Integracja wszystkich metryk popularności w jeden dzienny rekord dla danego artysty. W przypadku braku wartości google_trends_score przypisanie zera (0) i aktywacja flagi is_estimated = TRUE (rozwiązuje to problem braku danych dla niszowych twórców). Wyliczenie matematyczne miar dodatkowych, takich jak growth_velocity.
- **Plan weryfikacji:**

- *Zgodność kluczy obcych:* Testy referencyjne sprawdzające, czy każdy przypisany artist_id w tabeli faktów rzeczywiście istnieje w tabeli Dim_Artist (brak osieroconych metryk).
- *Wartości graniczne:* Weryfikacja logiczna, czy liczbowe wskaźniki (np. liczba słuchaczy czy popularność) nie przyjmują wartości ujemnych z powodu błędów wyciągania danych z API.

4. Podsumowanie Etapu 2

W ramach drugiego etapu projektu MusicaBI pomyślnie przeszliśmy od początkowej koncepcji biznesowej do szczegółowego projektowania technicznego. Zaprojektowana architektura hurtowni danych, oparta na schemacie płatka śniegu, stanowi solidny i skalowalny fundament do budowy docelowego systemu analitycznego.

Najważniejsze osiągnięcia tego etapu to:

- **Wyznaczenie KPI:** Zdefiniowaliśmy kluczowe wskaźniki efektywności, które trafią na samą górę dashboardu i pozwolą decydentom (menedżerom A&R) na natychmiastową ocenę sytuacji rynkowej .
- **Zaprojektowanie modelu wielowymiarowego:** Ustaliliśmy ziarno na poziomie jednego artysty i jednego dnia, przygotowaliśmy centralną tabelę faktów rejestrującą codzienne metryki oraz tabele wymiarów nadające im odpowiedni kontekst biznesowy (kto, gdzie, kiedy) .
- **Określenie hierarchii:** Wytyczyliśmy ścieżki nawigacyjne (m m.in. czasowe i geograficzne), które pozwolą użytkownikom na swobodne przechodzenie między różnymi poziomami szczegółowości danych .
- **Zaplanowanie procesu ETL:** Stworzyliśmy logiczną mapę procesu, identyfikując źródła danych (API), docelowe tabele oraz niezbędne transformacje (takie jak czyszczenie tekstu, obsługa wartości NULL czy deduplikacja po dedykowanych kluczach) .

Dzięki powyższym krokom struktura bazy danych dla MusicaBI jest spójna i gotowa do fizycznej implementacji skryptów zasilających (ETL), co w konsekwencji pozwoli na stworzenie w pełni interaktywnego narzędzia Business Intelligence.